



MarketIA Studio

*Generación de Imágenes y Síntesis de
Voz para la Automatización de
Marketing*

Problemática

Un pequeño emprendimiento puede tener una buena foto de su producto, pero no necesariamente cuenta con un estudio, edición o material suficiente para redes y tienda en línea.




Objetivo

Convertir una foto sencilla tomada con el celular en varias imágenes con apariencia de marketing, además de sugerir un copy y narrarlo en audio.

Arquitectura del Sistema



Modelos usados



CLIP

Clasificación zero-shot.

Compara la imagen contra una lista de categorías de productos y devuelve la categoría con mayor probabilidad.

BLIP-large

Generación de descripción.

Produce una oración en inglés sobre lo que aparece en la imagen.

Stable Diffusion 1.5

Generación img2img.

Combina la descripción con un estilo y crea una nueva imagen de apariencia lifestyle.

Piper TTS

Texto a voz local.

Narra el copy en español sin depender de una API externa.

Modelos de apoyo



MarianMT

Traducción EN→ES.

opus-mt-en-es traduce la descripción de BLIP para narrarla en español.

rembg

Recorte del producto.

Separa el producto del fondo y crea la máscara para el inpainting.

SD Inpainting

Fondo generado.

Solo inventa el fondo; el producto se pega con sus píxeles originales.

Applio / RVC

Conversión de voz (opcional).

Convierte la narración de Piper a la voz pública OpenSLR SLR72.

Generación de varias variantes



El parámetro:

```
def run_product_pipeline(x, strength=0.6, n_variants=3, surprise=False):  
    """Anything in, never raises. Always returns (list_of_images, message, audio_path)."""  
    try:  
        img = coerce_image(x)  
    except ValueError as e:  
        return [], str(e), None
```

Permite generar de 1 a 3 variantes. Con `surprise=True` los estilos se eligen al azar.

Estilos disponibles

img2img — Stable Diffusion

- Atardecer en la playa
- Loft minimalista
- Mercado vintage
- Neón nocturno
- Estudio meme (modo broma)

La descripción de BLIP más el prompt del estilo guían la nueva imagen (strength = 0.6).

Inpainting — fondo generado

- Fondo negro profesional
- Joyería en busto (fondo negro dramático)

rembg recorta el producto; SD solo genera el fondo y el producto se pega con sus píxeles originales, sin distorsión.

Generación del copy



El proyecto no utiliza un LLM para generar libremente el texto publicitario. Utiliza tres plantillas:

```
def make_social_caption(category, caption_text):  
    """Plantilla simple (no un modelo nuevo) para un pie de foto listo para redes.  
    La descripción de BLIP viene en inglés -- se muestra tal cual, sin traducir,  
    para no inventar contenido que el modelo no dijo."""  
    template = random.choice(SOCIAL_CAPTION_TEMPLATES)  
    return template.format(category=category, caption=caption_text)
```

Coloca dentro de ellas la categoría y la descripción obtenida de BLIP.

Texto a voz

La función

```
def narrate_caption(text, out_path):  
    """Social caption text -> narrated .wav at out_path, or None on failure.  
    Two audio models in sequence: Piper (Section 3) synthesizes the raw  
    speech, then, if USE_VOICE_CLONING is on, the RVC voice model (Section 3b,  
    trained on L22's public voice) converts it to that voice. If the RVC step  
    fails for any reason -- or was turned off -- falls back to the plain  
    Piper narration instead of losing the audio output. Never raises, same  
    contract as the rest of this pipeline."""
```

toma el guion de narración y utiliza:

```
    with wave.open(piper_path, 'wb') as wf:  
        piper_voice.synthesize_wav(clean, wf, syn_config=AD_VOICE_CONFIG)  
except Exception as e:  
    print(f'[narrate_caption] {type(e).__name__}: {e}')  
    return None
```

para generar un archivo .wav.

El guion une la categoría con la descripción traducida por MarianMT. Si USE_VOICE_CLONING = True, el audio se convierte con RVC a la voz pública; si falla, se conserva la voz de Piper.

Función Principal

La función que conjunta todo el flujo es

```
def run_product_pipeline(x, strength=0.6, n_variants=3, surprise=False):  
    """Anything in, never raises. Always returns (list_of_images, message, audio_path)."""  
    try:  
        img = coerce_image(x)  
    except ValueError as e:  
        return [], str(e), None
```

coerce_image → analyse_product (CLIP + BLIP + MarianMT) → generate_lifestyle → copy y narración → reporte. Nunca lanza errores: siempre devuelve (imágenes, mensaje, audio).

Interfaz

Finalmente se construye la interfaz con:

```
with gr.Blocks(title='Product Photo Generator') as app:
    gr.Markdown('# Product Photo Generator\nUpload a photo of your product. It identifies the '
                'category, describes it, generates lifestyle-style marketing photos, and narrates '
                'the suggested caption out loud.\n\n'
                '_Uploaded photos are stripped of EXIF/GPS metadata before processing._')
    with gr.Row():
        with gr.Column():
```

Controles: foto, intensidad del estilo (0.3–0.9), número de variantes (1–3) y la casilla «Sorpréndeme».


Salidas: galería de variantes, reporte con la etiqueta «Generado con IA» y la narración en audio, con un enlace público de Gradio.

```
app.queue().launch(share=True)
```

Product Photo Generator

Upload a photo of your product. It identifies the category, describes it, generates lifestyle-style marketing photos, and narrates the suggested caption out loud.

Uploaded photos are stripped of EXIF/GPS metadata before processing.



Style strength

0.3

0.9

0.6

🔄

Number of variants

1

3

3

🔄

☐

🎨 Sorpréndeme con el estilo

Lifestyle versions

Sugerencia de copy: Cuando tu una taza se ve así de bien... 🍷

#ProductoDelDía #MadeWithLove

🔊 Narración: lista, reproducéla abajo

🎵 🔊 Narración del copy (texto a voz)

0:000:13

🔊

1x

⏮

▶


⏭

Protección de la privacidad

Como medida de privacidad, el sistema elimina los metadatos EXIF de las fotografías antes de procesarlas, evitando exponer información como coordenadas GPS o datos del dispositivo. Sin embargo, esta medida no elimina información sensible que sea visible directamente dentro de la imagen.

```
def strip_exif(img):  
    """Return a copy of img with all EXIF metadata removed (GPS included).  
  
    ETHICS GUARDRAIL. A phone photo's EXIF can carry exact GPS coordinates.  
    Once this app's Gradio link is public, that metadata would travel with  
    any image we display or save, silently leaking where the photo was  
    taken -- so this runs on every upload, before anything else touches  
    the image. Does NOT cover: location visible in the pixels themselves  
    (a street sign, a house number, a distinctive background) -- only the  
    hidden file metadata.  
    """
```

Flujo de Operación



Flujo de Operación

La idea principal es separar el problema en etapas: primero entender qué producto aparece en la imagen con CLIP, después describirlo con BLIP y traducir esa descripción con MarianMT. Con ella, Stable Diffusion genera nuevas fotografías (img2img o inpainting) y, finalmente, el guion se narra con Piper TTS, opcionalmente convertido a otra voz con RVC. Gradio funciona como la capa que integra todo este pipeline en una aplicación interactiva.

Pruebas y resultados



Clasificación (CLIP) y descripción (BLIP) de las 4 fotos de prueba:

Foto	Categoría (CLIP)	Confianza	Descripción (BLIP)
Collar.jpeg	un collar	98.1%	a gold heart pendant on a gold chain on a white blanket
cadena.jpg	un collar	97.5%	a close up of a silver chain on a white background
cup.jpg	una taza	98.6%	a white cup with a gold handle sitting on a table
t-shirt.jpg	una playera o prenda de ropa	99.8%	a white t-shirt hanging on a hanger against a concrete wall

4 de 4 categorías correctas (97.5 – 99.8%) · 6 de 6 entradas hostiles sin errores (None, numpy, gris, RGBA, 1×1, 12 MP).

Corrida real con cadena.jpg: CLIP 45 ms · BLIP 0.59 s · MarianMT 262 ms · conversión RVC ~14 s · VRAM pico 7.31 / 15.6 GB · 3 variantes guardadas en Drive.

Ética y transparencia

- Etiqueta visible: el reporte dice «Generado con IA — no es la foto original» y la narración lo repite en voz.
- Voz con licencia: RVC se entrenó con la voz pública OpenSLR SLR72 (CC BY-SA 4.0), citada y sin presentarla como una persona real.
- Privacidad: `strip_exif()` quita metadatos y GPS antes de procesar cada foto, porque el enlace de Gradio es público.
- Fidelidad: en los estilos de fondo negro el producto conserva sus píxeles originales.

Limitaciones y trabajo futuro

Limitaciones

- Copy con plantillas fijas: sin concordancia de género («Cuando tu un collar...») y descripción en inglés.
- CLIP siempre elige una categoría: una imagen negra salió «producto alimenticio» (28.5%).
- img2img puede alterar el producto.
- Requiere T4 (7.31 GB de VRAM pico); RVC tarda ~10.5 min en entrenar y ~14 s por narración.

Trabajo futuro

- Umbral de confianza en CLIP para rechazar fotos que no son productos.
- Copy en español con concordancia de género.
- Marca de agua «IA» dentro de cada imagen generada.
- Quitar YOLO (se carga pero ya no se usa) y guardar el modelo RVC para no reentrenarlo.

Conclusiones

El proyecto demuestra cómo diferentes modelos de inteligencia artificial pueden integrarse en un solo flujo para transformar una fotografía sencilla de un producto en contenido útil para marketing. La combinación de CLIP, BLIP, MarianMT, Stable Diffusion, Piper TTS y RVC permite clasificar, describir, traducir, generar nuevas imágenes y crear una narración de manera automatizada. Además, el proyecto considera la privacidad (eliminación de metadatos EXIF), la transparencia (etiqueta «Generado con IA» en el reporte y en la narración) y el uso responsable de la voz (un dataset público con licencia). En conjunto, la propuesta muestra cómo la IA generativa puede convertirse en una herramienta práctica para apoyar a pequeños emprendedores en la creación de contenido digital.